Математическая статистика

14 июня 2020 г.

Содержание

1 Постановка задач математической статистики

Сравним задачи теории вероятностей и математической статистики

1.1 Задачи теории вероятностей

Заданы:

- Вероятностное пространство $\langle \Omega, \Sigma, P \rangle$.
- Случайная величина $X : \Omega \to \mathbb{R}^n$.

Требуется получить различного рода характеристики величины X и величин , получающихся из X.

1.2 Задачи математической статистики

Определение. *Статистическим экспериментом* называется четверка

$$\langle \mathcal{X}, \mathcal{A}, P_\theta, \Theta \rangle.$$

Здесь:

- $\mathcal{X}$ – множество *наблюдений*.
- $\mathcal{A}$ – σ-алгебра подмножеств $\mathcal{X}$.
- P_θ – известная с точностью до неизвестного параметра θ вероятностная мера – закон распределения наблюдаемых данных.
- Θ – множество допустимых значений неизвестного параметра, то есть $\theta \in \Theta$.

Задачей математической статистики является получение той или иной информации о законе распределения наблюдаемых данных $P = P_\theta$.

Определение. *Статистикой* называется измеримая функция

$$f : \mathcal{X} \to A.$$

Для произвольного A.

Определение. Пусть

$$\overline{X} = \langle X_1, \ldots, X_n \rangle.$$

Где $X_i \sim X$ – одинаково распределенные случайные величины. Соответствующая модель называется *моделью независимой однородной выборки*.

Определение. *Гипотезой H* называется подмножество Θ:

$$H \subseteq \Theta.$$

Перечислим некоторые задачи математической статистики.

- Оценивание параметра θ или какой-либо функции $g(\theta)$, то есть построение статистики $\hat{g} : \mathcal{X} \to \Theta$. Оценивание может быть:

  – *точечным*, то есть указание численной оценки $g(\theta)$

  – *длительным*, то есть указание множества, с фиксированной вероятностью содержащего $g(\theta)$

- Проверка гипотез. Пусть имеется разбиение Θ на гипотезы: $\Theta = \bigsqcup_{n \in N} H_n$. Тогда проеркой гипотезы назовем построение *теста* (*критерия*), то есть отображения

  $$\varphi : \mathcal{X} \to N.$$

  Которое по наблюдению выдает номер гипотезы, которому это наблюдение "соответствует".

Естественно, перечисленные задачи можно оценивать с точки зрения качества. В этом смысле всегда требуется с точки зрения какой-либо метрики построить "лучшую" оценку.

2 Частота как оценка вероятности события и её свойства. Построение доверительного интервала для вероятности события на базе асимптотической нормальности частоты.

Теорема 2.1. (Яков, Бернулли)
Пусть имеется $\xi_i \sim \xi$ – последовательность одинаково распределенных и попарно независимых случайных величин. Пусть

$$\overline{\xi}_n = \frac{1}{n}\sum_{i=1}^{n}\xi_n = \frac{k_n}{n}.$$

Тогда

$$\overline{\xi}_n \underset{n\to+\infty}{\rightrightarrows} p.$$

Теорема 2.2. (Центральная предельная теорема, простейший вариант)
Пусть случайные величины $X_i \sim X$ независимы и одинаково распределены, причем $\exists E(X), D(X)$. Тогда для случайной величины

$$Y_n = \frac{\overline{X}_n - E\left(\overline{X}_n\right)}{\sigma\left(\overline{X}_n\right)}.$$

Верно:

$$F_{Y_n} \underset{\mathbb{R}}{\rightrightarrows} F_{N(0,1)}.$$

Теорема 2.3. (Свойства частоты как оценки p)
Пусть $\xi \sim B(p)$. Тогда

$$\hat{p} = \frac{k_n}{n}$$

Является несмещенной асимптотически нормальной оценкой p, то есть

$$E(\hat{p}) = p,$$

$$\sqrt{n}\cdot(\hat{p}-p) = Y_n \xrightarrow{P_{n,\theta}} Y \sim N(0,\Delta^2(p)),\ \Delta^2(p) = p(1-p).$$

Доказательство.

- Покажем несмещенность:

$$E(\hat{p}) = E\left(\frac{k_n}{n}\right) = \frac{1}{n}np = p.$$

- Асимптотическая нормальность с нормирующим множителем $\Delta^2(p) = p(1-p)$ следует непосредственно из центральной предельной теоремы.

■

На базе асимптотической нормальности можно построить доверительный интервал. Проделаем это на примере частоты. Выпишем определение асимптотической нормальности:

$$Y_n = \frac{\sqrt{n} \cdot (\hat{p} - p)}{\sqrt{p(1-p)}} \to N(0,1).$$

Это буквально означает:

$$P_{n,\theta}(Y_n < t) \to F_{N(0,1)}(t).$$

Раскроем определение Y_n, возьмем его по модулю и воспользуемся квантилью:

$$P_{n,\theta}\left(\left|\frac{\sqrt{n} \cdot (\hat{p} - p)}{\sqrt{p(1-p)}}\right| < t_\gamma\right) \to \gamma \iff P_{n,\theta}\left(\frac{\sqrt{p(1-p)}}{\sqrt{n}} t_\gamma + \hat{p} > p > -\frac{\sqrt{p(1-p)}}{\sqrt{n}} t_\gamma + \hat{p}\right) \to \gamma.$$

Здесь $\gamma = P(|\xi| < t_\gamma),\ \xi \sim N(0,1)$. Построим д

3 Постановка выборочной статистической модели. Точечная оценка параметра и характеристики.

Определение. Напомним, что *точечной оценкой* параметра θ или какой-либо функции $g(\theta)$ называют численную оценку этой величины.

Пусть $\hat{g}_n$ *является некоторой точечной оценкой* $g = g(\theta)$.

Определение. $\hat{g}_n$ называется *несмещенной*, если $E(\hat{g}_n) = g(\theta)$.

Определение. $\hat{g}_n$ называется *состоятельной*, если $\hat{g}_n \underset{P}{\Longrightarrow} g(\theta)$ при $n \to \infty$.

Определение. $\hat{g}_n$ называется *асимптотически нормальной*, если

$$\frac{\sqrt{n}(\hat{g}_n - g(\theta))}{\sigma(g(\theta))} \xrightarrow[n\to\infty]{} N(0,1).$$

Определение. $\hat{g}_n$ называется *эффективной* в классе оценок K, если для любой другой оценки $\hat{g}_n^* \in K$ имеет место неравенство:

$$E(\hat{g}_n - g(\theta))^2 \leqslant E(\hat{g}_n^* - g(\theta))^2.$$

4 Функции потерь и функции риска, состоятельность оценки характеристики, достаточное условие для состоятельности оценки.

Определение. *Оценкой* $g(\theta)$ называется статистика вида

$$\hat{g} : \mathcal{X} \to g(\Theta).$$

Определение. Пусть $\hat{g}(\theta)$ – оценка $g(\theta)$. Тогда *функцией потерь* называется неотрицательная функция $l(\hat{g}, g(\theta))$, характеризующая “близость” оценки к настоящему значению.

Замечание. Обычно в качестве функции потерь рассматривают функцию вида

$$l(\hat{g}, g(\theta)) = \omega(\|\hat{g}, g(\theta)\|).$$

Здесь ω – неотрицательная монотонно возрастающая функция, $\omega(0) = 0$.

Замечание. l являтся случайной величиной.

Определение. *Риском* называется функция

$$R(\hat{g}, \theta) \stackrel{def}{=} E_\theta(l(\hat{g}, g(\theta))).$$

Замечание. Риск – функция параметра θ и способа оценивания $\hat{g}$.

Опишем самые важные для нас виды функции потерь и риска.

Определение. Определим функцию потерь индикатором отклонений:

$$l^\delta(\hat{g}, g(\theta)) = \omega^\delta(\|\hat{g}, g(\theta)\|).$$

Где

$$\omega(t) = \mathbb{1}_\delta(t) = \begin{cases} 0, \ t < \delta \\ 1, \ t \geqslant \delta \end{cases}.$$

Соответствующий риск будет вероятностью отклонения:

$$R^\delta(\hat{g}, \theta) = E_\theta(l(\hat{g}, g(\theta))) = 0 \cdot P_\theta(\|\hat{g} - g(\theta)\| < \delta) + 1 \cdot P_\theta(\|\hat{g} - g(\theta)\| \geqslant \delta) = P_\theta(\|\hat{g} - g(\theta)\| \geqslant \delta).$$

Определение. При асимптотическом подходе оценка называется *состоятельной*, если

$$\forall \delta > 0 \ R^\delta(\hat{g}_n, \theta) = P_{n,\theta}(\|\hat{g}_n - g(\theta)\| \geqslant \delta) \xrightarrow[n \to +\infty]{} 0.$$

Или, что то же самое:

$$\hat{g}_n \xrightarrow[n \to +\infty]{P_{n,\theta}} g(\theta).$$

Определение. *Квадратичной функцией потерь* называется функция

$$l_2(\hat{g}, g(\theta)) = \|\hat{g} - g(\theta)\|^2.$$

Соответствующий ей риск называется *квадратичным*:

$$R_2(\hat{g}, \theta) = E_\theta(\|\hat{g} - g(\theta)\|^2).$$

Теорема 4.1. (Достаточное условие для состоятельности оценки)
$R_2(\hat{g}_n, \theta) \xrightarrow[n\to+\infty]{} 0 \Longrightarrow$ оценка состоятельна.

Доказательство.

$$\begin{aligned}\forall \delta > 0\ R^\delta(\hat{g}_n, \theta) &= P(\|\hat{g}_n - g(\theta)\| \geqslant \delta) = P(\|\hat{g}_n - g(\theta)\|^2 \geqslant \delta^2) \\ &\leqslant \frac{E_\theta(\|\hat{g}_n - g(\theta)\|^2)}{\delta^2} = \frac{R_2(\hat{g}_n, \theta)}{\delta^2} \xrightarrow[n\to+\infty]{} 0.\end{aligned}$$

■

5 Вид квадратичного риска в случае одномерной характеристики.

Определение. *Смещением* оценки называется величина

$$b(\hat{g},\theta) = g(\theta) - E_\theta(\hat{g}).$$

Определение. Оценка называется *несмещенной*, если $b(\hat{g},\theta) = 0$.

Теорема 5.1. $R_2(\hat{g},\theta) = D_\theta(\hat{g}) + b^2(\hat{g},\theta)$.

Доказательство.

$$\begin{aligned}
R_2(\hat{g},\theta) &= E_\theta(\|\hat{g} - g(\theta)\|^2) = E_\theta(\hat{g} - E_\theta(\hat{g}) - (g(\theta) - E_\theta(\hat{g})))^2 \\
&= E_\theta(\hat{g} - E_\theta(\hat{g}))^2 + (g(\theta) - E_\theta(\hat{g}))^2 - \underbrace{2(g(\theta) - E_\theta(\hat{g}))(E_\theta\hat{g} - E_\theta\hat{g})}_{0} \\
&= D_\theta(\hat{g}) + b^2(\hat{g},\theta).
\end{aligned}$$

■

Следствие 5.2. Для одномерных несмещенных оценок квадратичный риск в точности равен дисперсии оценки:

$$R_2(\hat{g},\theta) = D_\theta(\hat{g}).$$

6 Постановка задачи доверительного оценивания, доверительный интервал.

При оценивании параметров или характеристик распределений мы в качестве результата получаем числовое значение $\hat{g}(X) \in g(\Theta)$. Такой способ оценивания мы называем *точечной оценкой*. Заранее не понятно, насколько результат соответствует действительности. Для того, чтобы можно было оценивать качество результата, нужно предъявлять не точку, а подмножество в $g(\Theta)$, содержащее в некотором смысле наиболее подходящие значения.
Задача доверительного оценивания ставится следующим образом: задана величина $\gamma \in (0, 1)$, называемая *уровнем надежности*. По заданному наблюдению X и значению надежности требуется построить доверительную область надежности.

Определение. *Доверительной областью надежности* называется $\widetilde{G}_\gamma \subseteq G = g(\Theta)$, обладающая свойством:

$$\forall \theta \in \Theta \; P_\theta(g(\theta) \in \widetilde{G}_\gamma) \geqslant \gamma.$$

То есть множество, с достаточной вероятностью содержащее оцениваемую величину.

Определение. В случае одномерной оценки чаще всего доверительные области надежности выбирают в виде промежутков, которые называются *доверительными интервалами*.

Определение. В асимптотическом случае (когда имеется последовательность оценок и статистических экспериментов) последовательность *асимптотических областей надежности* $\widetilde{G}_{n,\gamma}$ задается условием:

$$\forall \theta \in \Theta \; \lim P_{n,\theta}(g(\theta) \in \widetilde{G}_{n,\gamma}) \geqslant \gamma.$$

Определение. Аналогично задается последовательность асимптотических доверительных интервалов в случае одномерной характеристики.

7 Определение несмещенности и асимптотической нормальности оценки характеристики. Построение доверительного интервала для характеристики на базе асимптотической нормальности ее оценки.

Определение. Напомним, оценка называется *несмещенной*, если

$$b(\hat{g},\theta) = g(\theta) - E_\theta(\hat{g}) = 0.$$

Определение. Последовательность оценок $\hat{g}_n$ называется *асимптотически нормальной*, если

$$\sqrt{n}\cdot(\hat{g}_n - g(\theta)) = Y_n \xrightarrow{P_{n,\theta}} Y \sim N(0,\Delta^2(\theta)).$$

Определение. Величина $\Delta(\theta)$ из определения асимптотически нормальной оценки называется *нормирующим множителем*.

Замечание. Определение асимптотически нормальной оценки можно переписать так:

$$\frac{\sqrt{n}\cdot(\hat{g}_n - g(\theta))}{\Delta(\theta)} \xrightarrow{P_{n,\theta}} Y \sim N(0,1).$$

На базе асимптотической нормальности можно построить доверительный интервал. Выпишем определение асимптотической нормальности:

$$Y_n = \frac{\sqrt{n}\cdot(\hat{g} - g(\theta))}{\Delta(\theta)} \to N(0,1).$$

Это буквально означает:

$$P_{n,\theta}(Y_n < t) \to F_{N(0,1)}(t).$$

Раскроем определение Y_n, возьмем его по модулю и воспользуемся квантилью:

$$P_{n,\theta}\left(\left|\frac{\sqrt{n}\cdot(\hat{g} - g(\theta))}{\Delta(\theta)}\right| < t_\gamma\right) \to \gamma \Longleftrightarrow P_{n,\theta}\left(\frac{\Delta(\theta)}{\sqrt{n}}t_\gamma + \hat{g} > g(\theta) > -\frac{\Delta(\theta)}{\sqrt{n}}t_\gamma + \hat{g}\right) \to \gamma.$$

Здесь $\gamma = P(|\xi| < t_\gamma),\ \xi \sim N(0,1)$.

8 Постановка задачи проверки гипотез

Определение. *Гипотезой* называется множесто предполагаемых зафиксированных значений некоторого подмножества неизвестных параметров:

$$H : \theta \in \Theta_H \subseteq \Theta.$$

Определение. Гипотезу называют *простой*, если $|H| = 1$.

Определение. Гипотезу называют *сложной*, если $|H| > 1$.

Определение. Гипотезами *согласия* называют набор из двух гипотез: основной H_0 и альтернативы H_1, причем $H_0 = \overline{H_1}$.

Определение. Правило принятия или отклонения основной гипотезы H_0 называют *тестом (критерием)* проверки гипотезы:

$$\varphi(\mathcal{X}) : \mathcal{X}_n \to \{0, 1\}.$$

При этом:

- $\mathcal{X}_{n,0}$ называют *допустимым множеством*.
- $\mathcal{X}_{n,1}$ называют *критическим множеством*.
- $\mathcal{X}_{n,0} \sqcup \mathcal{X}_{n,1} = \mathcal{X}_n$.

Определение. Случайная величина $L(\overline{X}) : X_n \to \mathbb{R}$ называется *тестовой статистикой*, если она служит порогом для правила принятия или отклонения основной гипотезы:

$$\varphi(\overline{X}) = \begin{cases} 0, \ L(\overline{X}) < T\,(H_0) \\ 1, \ L(\overline{X}) \geqslant T\,(H_0) \end{cases}.$$

Где T называют *порогом принятия решения*.

9 Ошибки первого и второго рода и их вероятности как критерий качества критерия (теста) проверки гипотез. Подход Неймана-Пирсона.

Определение. *Ошибкой I рода* называют отклонение основной гипотезы, в то время как она была верна.

Определение. *Ошибкой II рода* называют принятие основной гипотезы, в то время как она не была верна.

Определение. α называют *вероятностью ошибки I рода*:

$$\alpha(\varphi,\theta) \overset{def}{=} P_\theta(\mathcal{X}_{n,1}),\ \theta \in \Theta_{H_0}.$$

Определение. *Уровнем значимости теста* называют верхнюю границу вероятности ошибки I рода по всем возможным наблюдаемым значениям неизвестных параметров, отвечающих основной гипотезе:

$$\alpha(\varphi) \overset{def}{=} \sup_{\theta\in\Theta_{H_0}} \alpha(\varphi,\theta).$$

Определение. β называют *вероятностью ошибки II рода*:

$$\beta(\varphi,\theta) \overset{def}{=} P_\theta(\mathcal{X}_{n,0}),\ \theta \in \Theta_{H_1}.$$

Определение. *Мощностью теста* называют следующую величину:

$$\gamma(\varphi,\theta) \overset{def}{=} 1-\beta(\varphi,\theta).$$

Подход Неймана-Пирсона.
Зафиксируем $\alpha \in (0,1)$ (обычно выбирают малое значение). Будем считать это значение минимальной допустимой величиной ошибки I рода (*допустимый уровень значимости*).
Рассмотрим множество всех тестов таких, что:

$$\overline{\Phi}_\alpha = \{\varphi = \varphi(x) \mid \alpha(\varphi) \leqslant \alpha\}.$$

Среди этих тестов выбирается тест с минимальным значением β.
В асимптотических задачах ограничения накладываются на предельные значения.

10 Эмпирическая функция распределения (ЭФР). Построение, свойства ЭФР при фиксированном значении аргумента (использовать свойства частоты).

Определение. *Эмпирической функцией распределения (ЭФР)* называют следующую оценку функции распределения генеральной совокупности:

$$F_n(t) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{1}_{(-\infty,t)}.$$

Иными словами, значение ЭФР в точке t равно отношению числа наблюдений, меньших t, к их общему числу n.

Свойства ЭФР:

1. ЭФР кусочно-постоянна.
2. Скачки ЭФР имеют вид $\frac{k}{n}$ для некоторого $k \in (1; n)$.
3. Область принимаемых значений: $[0; 1]$.
4. Частота может служить как оценка функции распределения генеральной совокупности. При фкисированном $t = t_0$:

$$F_x(t_0) \approx F_n(t_0) = \xi_1 + \ldots + \xi_n = \frac{k_n}{n} \text{ – частота.}$$

5. $F_n(t)$ является состоятельной оценкой:

$$F_n(t_0) = \overline{\xi}_n : F_n(t_0) \xrightarrow[p=1]{} F_x.$$

6. $F_n(t)$ является асимптотически нормальной оценкой.

11 Свойства ЭФР в целом. Расстояние Колмогорова, Смирнова. Теоремы Гливенко-Кантелли, Колмогорова, Мизеса-Смирнова. Построение доверительной полосы для функции распределения.

Со свойствами ЭФР можно ознакомиться в предыдущем разделе.

Определение. *Расстояние Колмогорова*:

$$\rho_\infty(F_n, F_x) = \sup_t |F_n(t) - F_x(t)|.$$

Определение. *Расстояние Смирнова*:

$$\rho_2^2(F_n, F_x) = \int_{\mathbb{R}} (F_n(t) - F_x(t))^2 dF_x(t).$$

Теорема 11.1. (Гливенко-Кантелли)
Пусть $\mathcal{F}$ – множество функций распределения. Тогда $\forall F_x(t) \in \mathcal{F}$ верно:

$$\rho_\infty(F_n, F_x) \xrightarrow[n\to\infty]{p=1} 0 \Rightarrow \rho_\infty(F_n, F_x) \xrightarrow[p]{} 0.$$

Замечание. $F_n(t)$ – состоятельная оценка $F_x(t)$ в расстояниях Колмогорова и Смирнова.

Пусть $\mathcal{F}_c ==$ множество всех непрерывных функций распределения.

Теорема 11.2. (Колмогоров)

$$P_{n,F}(\sqrt{n}\rho_\infty(F_n, F_x) < u) \xrightarrow[n\to\infty]{} \mathcal{K}(u) = \begin{cases} 0, \ u = 0 \\ \sum\limits_{j=-\infty}^{+\infty} (-1)^j e^{-2(ju)^2}, \ u > 0 \end{cases}.$$

Теорема 11.3. (Мизес-Смирнов)

$$P_{n,F}(\sqrt{n}\rho_2^2(F_n, F_x) < u) \xrightarrow[n\to\infty]{} \mathcal{S}(u),$$

где $\mathcal{S}(u)$ есть функция распределения следующей случайной величины:

$$\mathcal{U} = \sum_{j=1}^{\infty} \frac{\xi_j^2}{j^2\pi^2}, \ \xi_1, \dots, \xi_n, \dots \sim N(0,1), \text{ независимые.}$$

Замечание. Используя теорему Колмогорова, можно построить доверительную полосу для функции распределения.

Определение. *Доверительной полосой* называют часть плоскости, в которую с надежностью γ попадает функция распределения генеральной совокупности:

$$\begin{cases} F_n^-(t) = max(0, F_n(t) - \frac{u_\gamma}{\sqrt{n}}) \\ F_n^+(t) = min(1, F_n(t) + \frac{u_\gamma}{\sqrt{n}}) \end{cases}, \text{ где } \mathcal{K}(u_\gamma) = \gamma.$$

Утверждение 11.4.

$$P_x(F_n^-(t) \leqslant F_x(t) \leqslant F_n^+(t)) \xrightarrow[n\to\infty]{} \gamma.$$

Доказательство. $0 \leqslant F_x(t) \leqslant 1$ всегда, тогда:

$$\begin{aligned}
&P_x(F_n^-(t) \leqslant F_x(t) \leqslant F_n^+(t)) = \\
&\qquad = P_x\Big(F_n(t) - \frac{u_\gamma}{\sqrt{n}} \leqslant F_x(t) \leqslant F_n(t) + \frac{u_\gamma}{\sqrt{n}}\Big) \overset{\forall t}{=} \\
&\qquad \overset{\forall t}{=} P_x(\sqrt{n}|F_x(t) - F_n(t)| \leqslant u_\gamma) \overset{\forall t}{=} \\
&\qquad \overset{\forall t}{=} P_x(\sup_t |F_x(t) - F_n(t)| \leqslant u_\gamma) \xrightarrow{\text{th. Колмогорова}} \mathcal{K}(u_\gamma) = \gamma.
\end{aligned}$$

■

12 Критерии согласия Колмогорова и Мизеса-Смирнова.

Пусть $F_0(t)$ – заданная непрерывная функция распределения.

Поставим задачу проверки согласия:

$$H_0 \equiv (F_x(t) \equiv F_0(t)).$$

12.1 Критерий согласия Колмогорова

Определим тестовую статистику:

$$L(\overline{X}) = \sqrt{n}\rho_\infty(F_0, F_n).$$

По th. Колмогорова:

$$P(L(\overline{X}) < z) \xrightarrow[n\to\infty]{} \mathcal{K}(z),$$

где $\mathcal{K}$ – распределение Колмогорова. Тогда порогом принятия решения при уровне значимости α является квантиль распределения Колмогорова порядка $1-\alpha$ (далее $u_{1-\alpha}$).

Таким образом, определим тест:

$$\varphi(\overline{X}) = \begin{cases} 0, & \sqrt{n}\rho_\infty(F_0, F_n) < u_{1-\alpha} \\ 1, & \sqrt{n}\rho_\infty(F_0, F_n) \geqslant u_{1-\alpha} \end{cases}.$$

12.2 Критерий Мизеса-Смирнова

Определим тестовую статистику:

$$L(\overline{X}) = \sqrt{n}\rho_2^2(F_0, F_n).$$

По th. Мизеса-Смирнова:

$$P(L(\overline{X}) < z) \xrightarrow[n\to\infty]{} \mathcal{S}(z),$$

где $\mathcal{S}$ – распределение Мизеса-Смирнова. Тогда порогом принятия решения при уровне значимости α является квантиль распределения Мизеса-Смирнова порядка $1-\alpha$ (далее $s_{1-\alpha}$).

Таким образом, определим тест:

$$\varphi(\overline{X}) = \begin{cases} 0, & \sqrt{n}\rho_2^2(F_0, F_n) < w_{1-\alpha} \\ 1, & \sqrt{n}\rho_2^2(F_0, F_n) \geqslant w_{1-\alpha} \end{cases}.$$

12.3 Прикладной алгоритм:

1. Строится ЭФР.

2. Считается статистика критерия. Поскольку ЭФР является кусочно-постоянной, расстояние Колмогорова / Мизеса-Смирнова можно считать как верхнюю границу по соответствующим значениям расстояний в точках скачка.

3. Для заданного уровня значимости α находится квантиль распределения Колмогорова / Мизеса-Смирнова порядка $1-\alpha$.

4. Если значение тестовой статистики меньше полученного квантиля, следует принять нулевую гипотезу, иначе – оклонить.

13 Основные выборочные оценки и их свойства. Выборочное математическое ожидание. Выборочная дисперсия. Выборочные моменты. Выборочные медиана и квантили. Выборочные оценки ковариации и коэффициента корреляции.

Здесь X – произвольная рассматриваемая случайная величина.

13.1 Выборочное среднее / М.О.

Определение. Случайную величину $\overline{X}_n = EY = \sum\limits_{i=1}^{n} X_{(i)} \cdot \frac{1}{n} = \frac{1}{n}\sum\limits_{j=1}^{n} X_j$ называют *выборочным средним* некоторой выборки $X_{[n]}$ из генеральной совокупности X.

Выборочное среднее является выборочной точечной оценкой EX.

Свойства.

- Выборка является набором одинаково распределенных независимых случайных величин, из чего по законму больших чисел:

$$\overline{X}_n \xrightarrow[n\to\infty]{p} EX, \text{ если } \exists EX.$$

  Поэтому выборочное среднее является *состоятельной* оценкой EX.

- Выборочное среднее является *несмещенной* оценкой EX:

$$E_x\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} E(X_i) = EX, \text{ оо св-ву М.О.}$$

- Если $\exists EX, DX$, то по центральной предельной теореме:

$$Y_n = \frac{\overline{X}_n - E_x(\overline{X}_n)}{\sigma_x(\overline{X}_n)} = \frac{\overline{X}_n - EX}{\sigma(X)}\sqrt{n} \xrightarrow[n\to\infty]{F} Y \sim N(0,1),$$

  или

$$F_{Y_n}(t) \underset{n\to\infty}{\overset{\mathbb{R}}{\rightrightarrows}} F_Y(t).$$

  Из этого следует, что центрированное нормированное выборочное среднее сходится по распределению к стандартному нормальному распределению. Следовательно, выборочное среднее является *асимптотически нормальной* оценкой EX.

13.2 Выборочная дисперсия

Определение. Случайную величину $S_n^2 = D(X_{[n]}) = \sum\limits_{i=1}^{n}(X_{(i)} - EY)^2 \cdot \frac{1}{n} = \frac{1}{n}\sum\limits_{i=1}^{n}(X_i - \overline{X}_n)^2$ называют *выборочной дисперсией* некоторой выборки $X_{[n]}$ из генеральной совокупности X.

Выборочная дисперсия является выборочной точечной оценкой DX.

Свойства.

- Выборочная дисперсия является *состоятельной* оценкой DX:

$$S_n^2 \xrightarrow[n\to\infty]{P} E(X^2) - (EX)^2 = DX.$$

- Выборочная дисперсия является *смещенной* оценкой DX (не теряя общности, будем считать $EX = 0$, инвариантность DX относительно сдвига):

$$E(X^2) = DX,\ E_x(\overline{X}_n) = EX = 0$$
$$\Rightarrow E_X(\overline{X}_n^2) = D_X(\overline{X}_n) + (E_x(\overline{X}_n))^2 = \frac{DX}{n}$$
$$\Rightarrow E_X S_n^2 = E_X(\frac{1}{n}\sum_{i=1}^{n} X_i^2 - \overline{X}_i^2) = \frac{1}{n}nE(X^2) - \frac{DX}{n} = DX - \frac{DX}{n} = \frac{n-1}{n}DX.$$

- Выборочная дисперсия является *асимптотически нормальной* оценкой DX – *без доказательства*.

13.3 Несмещенная выборочная дисперсия

Определение. Чаще вместо S_n^2 используют *несмещенную (исправленную) оценку дисперсии*:

$$\sigma_n^2 = \frac{n}{n-1}S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X}_n),$$

Несмещенная выборочная дисперсия является выборочной точечной оценкой DX.

Свойства.

- *Состоятельность* следует из состоятельности S_n^2:

$$\sigma_n^2 \xrightarrow[n\to\infty]{p=1} DX.$$

- *Несмещенность* очевидна из доказательства смещенности выборочного среднего.

- Несмещенная оценка дисперсии является *асимптотически нормальной* оценкой DX – *без доказательства*.

13.4 Выборочные моменты

13.4.1 Выборочные начальные моменты

Определение. *Выборочным начальным моментом порядка* k называется статистика:

$$m_{n,k} = \frac{1}{n}\sum_{i=1}^{n} X_i^k, \ k = 1, 2, \ldots.$$

Эти выборочные характеристики можно считать выборочным средним для случайной величины $Z = X^k$:

$$m_{n,k} = \overline{Z}_k.$$

Следовательно, если $\exists E(X^k)$, то $m_{n,k}$ является *состоятельной* и *несмещенной* оценкой $E(X^k)$.

Если существует $E(X^{2k})$, то $m_{n,k}$ является *асимптотически нормальной* оценкой $E(X^k)$ с асимптотической дисперсией $\Delta^2 = E_x(Z^2) - (E_x(Z))^2$.

13.4.2 Выборочные центральные моменты

Определение. *Выборочным центральным моментом порядка* k называется статистика:

$$\mu_{n,k} = \frac{1}{n}\sum_{i=1} n(X_i - \overline{X}_n)^k.$$

Данные статистики являются *состоятельными, смещенными* оценками соответствующих центральных моментов генеральной совокупности.

13.5 Выборочная медиана

Определение. *Медианой* t_0 случайной величины X называют такое значение аргумента функции распределения $F_x(t)$, что для него выполняются неравенства:

$$\begin{cases} P(X \geqslant t_0) \geqslant \frac{1}{2} \\ P(X \leqslant t_0) \geqslant \frac{1}{2} \end{cases}.$$

Если $F_x(t) \in C(\mathbb{R})$, то $F_x(t_0) = \frac{1}{2}$.

Определение. Пусть $X_{(1)} \leqslant X_{(2)} \leqslant \ldots \leqslant X_{(n)}$ – упорядоченная выборка (вариационный ряд), тогда *выборочной vедианой* med_n называется следующая случайная величина:

$$med_n = \begin{cases} X_{(k)} = X_{\frac{n-1}{2}}, \text{ при } n = 2k - 1 \\ \frac{X_{(k)} + X_{(k+1)}}{2}, \text{ при } n = 2k \end{cases}.$$